ME315A_Lab08

João Vitor Expedito Silva de Oliveira RA:294836

Objetivo

Dados relacionais são uma constante no exercício da profissão do estatístico. Esta estratégia permite uma representação mais efetiva de dados estruturados, oferecendo a possibilidade de análises computacionalmente mais eficientes.

Os Dados

- 1. `title.basics0.tsv.gz` (Informações Básicas dos Filmes);
- 2. `title.ratings.tsv.gz` (Avaliações dos Filmes);
- 3. `title.principals0.tsv.gz` (Elenco e Equipe Técnica).

Atividade

Utilizando apenas operações por meio da biblioteca polars, responda:

```
import polars as pl

# Leitura das informações básicas dos filmes
basics = pl.read_csv(
    "title.basics0.tsv.gz",
    separator="\t",
    null_values="\\N",
    quote_char=None,
    infer_schema_length=0,
    columns=["tconst", "titleType", "primaryTitle", "genres"]
)

# Leitura das avaliações
ratings = pl.read_csv(
```

```
    "title.ratings.tsv.gz",
    separator="\t",
    null_values="\\N",
    quote_char=None,
    infer_schema_length=0
).with_columns(
    pl.col("averageRating").cast(pl.Float64),
    pl.col("numVotes").cast(pl.Int64)
)

# Seleção dos filmes e integração com as avaliações
filmes = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
)

filmes.head()
```

```
shape: (5, 6)
```

tconst	titleType	primaryTitle	genres	averageRating	numVo
str	str	str	str	f64	i64
tt0000009	movie	Miss Jerry	Romance	5.4	215
tt0000147	movie	The Corbett-Fitzsimmons Fight	Documentary,News,Sport	5.2	533
tt0000502	movie	Bohemios	null	4.4	18
tt0000574	movie	The Story of the Kelly Gang	Action,Adventure,Biography	6.0	932
tt0000591	movie	The Prodigal Son	Drama	5.7	28

1. Quais são os 5 filmes com as maiores notas (`averageRating`)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
(
    filmes
    .sort(
        ["averageRating", "numVotes"],
```

```
        descending=[True, True]
    )
    .select([
        "primaryTitle",
        "averageRating",
        "numVotes"
    ])
    .head(5)
)
```

```
shape: (5, 3)

 primaryTitle              averageRating   numVotes
 ---                       ---             ---
 str                       f64             i64

 Kaveri                    10.0            1023
 Kurukku                   10.0            451
 Jedal Dar Omghe 30 Metri  10.0            142
 Sargashte                 10.0            134
 Gorgeous Rascal           10.0            115
```

2. Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
(
    filmes
    .filter(pl.col("averageRating") > 8)
    .select(
        pl.col("genres").str.split(",")
    )
    .explode("genres")
    .drop_nulls("genres")
    .filter(pl.col("genres") != "")
    .group_by("genres")
    .len()
    .sort("len", descending=True)
    .head(1)
)
```

```
shape: (1, 2)
```

```
genres        len
---           ---
str           u32

Documentary   10564
```

3. Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
ids_filmes = (
    filmes
    .filter(pl.col("averageRating") > 7.5)
    .select("tconst")
)

(
    pl.scan_csv(
        "title.principals0.tsv.gz",
        separator="\t",
        null_values="\\N",
        quote_char=None,
        infer_schema_length=0
    )
    .filter(
        pl.col("category").is_in(["actor", "actress"])
    )
    .join(
        ids_filmes.lazy(),
        on="tconst",
        how="inner"
    )
    .select(["tconst", "nconst"])
    .unique()
    .group_by("nconst")
    .len()
    .sort("len", descending=True)
    .head(3)
    .collect()
)
```

```
shape: (3, 2)
```

```
nconst      len
---         ---
str         u32

nm0004660   199
nm0595934   155
nm3183374   124
```

```
Sys.setenv(TZ = 'America/Sao_Paulo')
Sys.time()
```

```
[1] "2026-10-14 22:54:17 -03"
```